BUSINESS INTELLIGENCE

PROYECTO FINAL · ENTREGA 1

RETAILBI

Diagnóstico, estrategia y diseño de una solución de BI

Integrante	Código
Juan David Pardo Gutierrez	506241031
Linda Valentina Quintero Quiroga	506241056
Daniel Felipe Rodríguez Angulo	506241129

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	23/10/2026
Repositorio GitHub	https://github.com/damoelrrr/BI-Entrega-1-Equipo.506241931-506241056-506241129.pdf

Los datos transaccionales que se adjuntan son sintéticos y se identifican expresamente como tales; las fuentes públicas externas se usan como contexto y contraste, no como ventas reales de RetailBI.

Resumen de la entrega

RetailBI es una organización minorista ficticia con cinco establecimientos en Bogotá que presenta información comercial dispersa, formatos de fecha inconsistentes y definiciones no estandarizadas de indicadores. Se propone una solución de BI con integración ETL, almacenamiento centralizado en PostgreSQL, modelo dimensional en estrella y visualización para el gerente comercial. De acuerdo con el escenario planteado, la madurez actual corresponde a la fase 2 del BIMM de siete fases (Datos accesibles sin BI) y la fase objetivo es la fase 4 (Data warehouse). Una fila de la tabla de hechos FactVentas representa una línea de venta: un producto vendido en una tienda en un día, identificada por venta_id. El análisis cuantitativo de ventas se desarrollará con 50.000 registros sintéticos reproducibles; estos no representan ventas observadas de una empresa real.

1. Caso de negocio

El presente proyecto propone el diseño de una solución de Business Intelligence (BI) para una empresa minorista ficticia denominada RetailBI, dedicada a la comercialización de productos de consumo cotidiano a través de establecimientos físicos. La organización opera en un entorno comercial competitivo, en el que resulta fundamental conocer el comportamiento de las ventas, identificar las preferencias de los consumidores y disponer de información confiable para orientar las decisiones comerciales y operativas.

Para el desarrollo de este caso académico, se plantea que se cuente con cinco establecimientos ubicados en Bogotá D. C., Colombia, y una estructura administrativa central encargada de coordinar las actividades comerciales. La empresa comercializa diferentes categorías de productos y genera diariamente información relacionada con las transacciones, las cantidades vendidas, los precios y las fechas de compra. Estos datos representan un recurso importante para comprender el desempeño de la organización y detectar oportunidades de mejora en sus operaciones.

Sin embargo, se plantea que la información de la empresa se encuentra distribuida en diferentes herramientas de registro, sin una estructura centralizada que facilite su integración y análisis. Esta situación dificulta consolidar los resultados de los establecimientos, comparar periodos u obtener una visión global del comportamiento comercial. Además, la preparación de informes puede requerir tareas manuales que consumen tiempo y aumentan el riesgo de inconsistencias entre los resultados obtenidos por diferentes responsables.

La falta de integración de los datos limita la capacidad de la organización para responder oportunamente a preguntas relevantes para el negocio. Por ejemplo, resulta difícil identificar de manera consistente qué categorías presentan mayores ingresos, cómo varían las ventas entre distintos periodos o qué productos muestran cambios significativos en su demanda. Asimismo, la ausencia de indicadores estandarizados puede generar interpretaciones diferentes sobre el desempeño de las tiendas y dificultar la comparación de resultados.

Ante esta situación, se identifica la necesidad de diseñar una solución de Business Intelligence que permita transformar los datos disponibles en información organizada, accesible y útil para la toma de decisiones. La propuesta contempla una arquitectura que integre distintas fuentes de información mediante procesos de extracción, transformación y carga (ETL), con el propósito de organizar los datos en un almacén centralizado. Sobre esta estructura se plantea desarrollar un modelo dimensional que facilite el análisis de las ventas desde diferentes perspectivas, como el tiempo, los productos, las categorías y los establecimientos, siempre que las fuentes seleccionadas contengan los atributos necesarios.

La solución propuesta busca facilitar la elaboración de informes consistentes y la identificación de patrones comerciales mediante indicadores como los ingresos por ventas, las unidades comercializadas y la evolución temporal de la demanda. Estos análisis podrían contribuir a reconocer las categorías con mejor desempeño, detectar periodos de mayor actividad comercial y proporcionar información para planificar campañas promocionales y decisiones de abastecimiento. No obstante, la evaluación de la rentabilidad real o de los niveles efectivos de inventario requerirá disponer de datos adicionales sobre costos y existencias.

El principal usuario de la solución será el gerente comercial, quien necesita contar con información histórica comparable para evaluar los resultados y orientar las decisiones relacionadas con la oferta de productos y el desempeño de los

establecimientos. Otros usuarios potenciales serán los responsables de tienda y el personal administrativo, que podrán utilizar los informes para comprender las tendencias de ventas y apoyar la planificación de sus actividades.

En conclusión, el objetivo principal del proyecto es diseñar una solución de Business Intelligence que permita integrar y analizar la información comercial de RetailBI para mejorar la disponibilidad, la consistencia y la utilidad de los datos en la toma de decisiones**.** Para alcanzar este objetivo, la primera entrega se centrará en el diagnóstico de la situación empresarial, la identificación y evaluación de las fuentes de datos, el análisis de madurez de BI y el diseño de una arquitectura y un modelo dimensional adecuados para las necesidades identificadas.

De esta manera, RetailBI dispondrá de una propuesta estructurada para evolucionar desde una gestión de información fragmentada hacia un enfoque de análisis integrado y basado en datos. La solución constituirá una base para las siguientes fases del proyecto, en las que podrán implementarse los procesos de integración, el almacén de datos y las herramientas de visualización que permitan convertir el diseño en una solución analítica funcional.

1.1 Organización y contexto

RetailBI es una empresa minorista perteneciente al sector comercial, dedicada a vender al consumidor productos de consumo cotidiano. Por esta razón la organización cuenta con cinco establecimientos físicos ubicados en Bogotá, Colombia, y una estructura administrativa central encargada de coordinar las actividades comerciales y operativas.

La empresa dispone de responsables de ventas, encargados de tienda y personal administrativo que participa en el registro y seguimiento de las operaciones. Los establecimientos generan información sobre las transacciones, los productos vendidos, las cantidades y los precios. No obstante, los datos se gestionan mediante herramientas y archivos parcialmente independientes, sin una plataforma centralizada que permita consolidar la información de todas las tiendas.

El máximo responsable del proyecto es el gerente comercial, quien debe evaluar el desempeño de las ventas y orientar las decisiones relacionadas con las categorías de productos, las campañas comerciales y las necesidades de abastecimiento. Para ello, necesita disponer de información histórica comparable y de indicadores confiables que permitan identificar patrones y diferencias entre periodos y establecimientos.

En la situación actual descrita, el gerente comercial no puede determinar de forma rápida y consistente qué categorías y productos presentan un mejor desempeño a lo largo del tiempo, cómo varían las ventas entre establecimientos ni qué tendencias históricas deberían tenerse en cuenta para planificar las compras. Estas limitaciones se deben, en el escenario planteado, a la dispersión de los datos, a la ausencia de definiciones comunes para los indicadores y a la falta de una estructura integrada para el análisis.

Por esta razón, se propone diseñar una solución de Business Intelligence basada en un almacén de datos y un modelo dimensional que consoliden la información disponible y permitan analizar las ventas desde distintas perspectivas. La viabilidad de estos análisis dependerá de la disponibilidad, calidad y compatibilidad de las fuentes que se seleccionen y validen durante el desarrollo del proyecto.

1.2 Síntomas de arquitectura accidental

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Fechas con formatos diferentes	Una tienda registra la fecha como 23/04/2024 y otra como 04-23-2024; al consolidar, una misma venta puede quedar en el mes equivocado.	Fuentes / Integración
S2	Datos de ventas dispersos	Cada tienda conserva archivos separados y el gerente debe reunirlos manualmente para obtener un consolidado.	Fuentes / Integración / Almacén

S3	Indicadores sin definición común	Un informe calcula la venta descontando los descuentos y otro no, así que el total de un mismo mes no coincide entre informes.	Almacén / Gobierno de datos

1.3 Preguntas de negocio

#	Pregunta	Tipo	Justificación
P0	¿Cómo evolucionan los ingresos y las unidades vendidas por tienda, categoría y mes?	BI	Es BI porque describe, con datos históricos estructurados, cómo evolucionaron ingresos y unidades; no predice ni recomienda.
P1	¿Qué productos y categorías generan mayores ingresos netos?	BI	Es BI porque ordena productos y categorías según los ingresos netos ya registrados: es un análisis descriptivo del pasado.
P2	¿Qué tiendas presentan mayor volumen de unidades vendidas?	BI	Es BI porque compara las unidades ya vendidas por tienda a partir de datos estructurados del almacén.
P3	¿Qué meses muestran aumentos o disminuciones en las ventas?	BI	Es BI porque identifica, sobre la serie mensual histórica, las alzas y caídas que ya ocurrieron.
P4	¿Qué nivel de ventas podría esperarse para los próximos meses a partir del historial?	BA	Es BA porque estima ventas futuras con un modelo predictivo entrenado con la historia mensual de 2023 a 2025.

2. Inventario de fuentes

2.1 Fuentes

Fuente	Procedencia	Formato	Registros / periodo	Descarga	Licencia / uso
F1- DANE, Encuesta Mensual de Comercio (EMC): https://www.dane.gov.co/index.php/estadisticas-por-tema/comercio-interno/encuesta-mensual-de-comercio-emc	DANE	XLSX (anex-EMC-ComercioMinorista-ago2026.xlsx)	Hoja 2.1 del anexo de comercio minorista (índices de ventas nominales por grupo de mercancía, base 2019 = 100): 92 registros mensuales, de enero de 2019 a agosto de 2026.	23/10/2026	Uso, aprovechamiento, transformación y análisis autorizados con atribución al DANE; sujeto a los términos y condiciones del portal.
F2-Datos Abiertos Bogotá, Dinámica	Secretaría Distrital de Desarrollo	DBF/GPKG	Recurso Empresas 2026 (DBF): 39.941	23/10/2026	CSV · 39.941 registros con corte a abril de

empresarial: https://datosabiertos.bogota.gov.co/dataset/dinamica-empresarial-bogota	Económico / Datos Abiertos Bogotá		registros con corte a abril de 2026; capas anuales en GPKG para 2023, 2024 y 2025.		2026 (recurso “Empresas 2026”). Las capas anuales en GPKG de 2023 a 2025 no se usan en esta entrega.
F3-RetailBI_ventas_sinteticas_50000.csv, generado para este proyecto	Elaboración propia	CSV	50.000 filas de ventas; periodo 2023 a 2025 (tres años).	23/10/2026	Elaboración propia · GPKG (GeoPackage, tabla sin geometría ventas_sinteticas): RetailBI_ventas_sinteticas_50000.gpkg · 50.000 filas, del 01/01/2023 al 31/12/2025 · Datos sintéticos creados para fines académicos; no corresponden a ventas reales.

2.2 Problemas de calidad detectados

Fuente	Campo	Problema	Ejemplo / forma de documentarlo
F1	Mes y Año (hoja 2.1)	El mes es texto con espacios iniciales y, en un caso, un punto sobrante; el año solo aparece en la primera fila de cada año y debajo de los datos hay filas de notas.	Enero de 2019 aparece como ' Enero.' y febrero de 2019 tiene el año vacío; tras agosto de 2026 sigue la fila 'Fuente: DANE - EMC'.
F2	Codigo CIIU Rev. 4 A.C y Localidad	Los códigos CIIU pierden el cero inicial (2.147 filas con menos de cuatro dígitos), 2.383 filas tienen 'Sin Localidad' y los nombres de localidad van sin tildes.	_id 130179: CIIU '112' en lugar de '0112'; _id 157221: Localidad 'Sin Localidad'; 'Engativa' en lugar de 'Engativá'.
F3	fecha_venta, tienda, producto	Los datos sintéticos llegan limpios; como permite el enunciado, en una copia de prueba se introducen formatos de fecha mezclados, espacios en nombres y nulos controlados.	Venta `V000181`: original `2023-01-05`, copia `05/01/2023`. Venta `V000566`: original `2023-01-15`, copia `01-15-2023`. Venta `V000193`: tienda `Kennedy`, copia `Kennedy`. Venta `V000150`: cantidad `3`, copia vacía.

Los ejemplos de F1 y F2 se tomaron de los archivos originales publicados por el DANE y por Datos Abiertos Bogotá. En F3, el archivo original (`datos/raw/`) no se modifica; las inconsistencias se introdujeron deliberadamente en `datos/inconsistencias/RetailBI_ventas_sinteticas_50000_inconsistencias.csv` y

cada cambio (venta, campo, valor original y valor modificado) está en `RetailBI_ventas_sinteticas_inconsistencias_log.csv`.

- **Los diccionarios de F1, F2 y F3 están en `datos/diccionarios/` y las muestras de 20 filas de cada fuente, en `datos/muestras/` (los tres archivos de cada carpeta llevan el prefijo F1, F2 y F3). Los diccionarios completos también están en el Anexo A.**

3. Diagnóstico de madurez

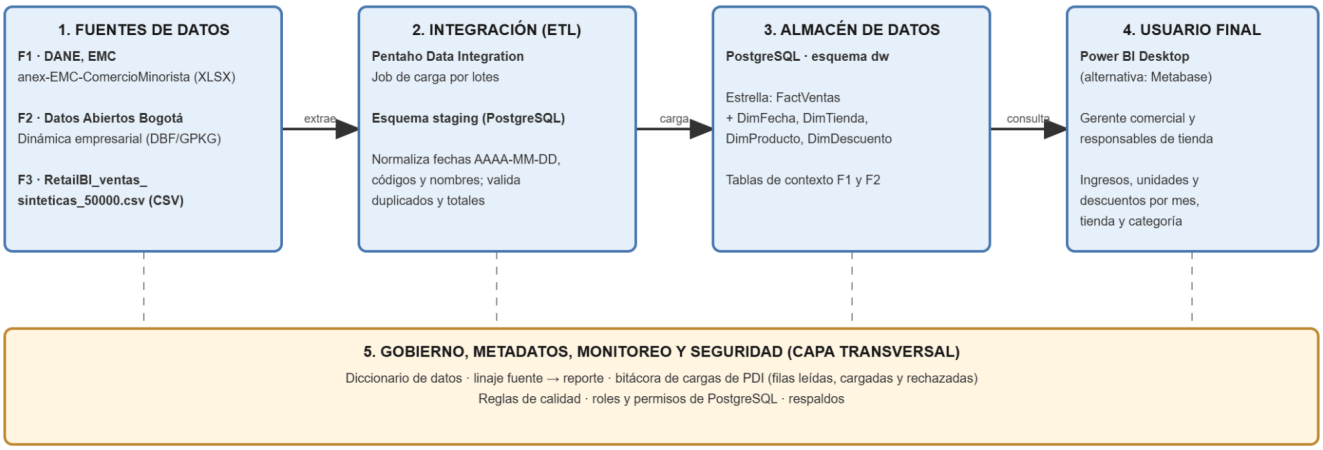
Elemento	Respuesta
Fase actual	Fase 2: Datos accesibles sin BI.
Evidencia	S2: las ventas de las cinco tiendas existen en archivos separados, es decir, los datos son accesibles, pero el consolidado se arma a mano. S1: cada fuente registra la fecha en un formato distinto y ningún proceso la normaliza. S3: no hay definiciones comunes de venta neta ni de descuento, así que los totales de distintos informes no son comparables. Los tres síntomas son parte del escenario planteado; en F3 las fechas vienen en formato ISO y S1 se simula en una copia de prueba (tabla 2.2).
Por qué no es la fase siguiente	La fase 3 (Procesos formales de decisión basados en datos) exige que las decisiones sigan un proceso establecido con datos consolidados e indicadores definidos. A RetailBI le falta un consolidado único de las cinco tiendas (S2), fechas homogéneas para comparar periodos (S1) y definiciones comunes de los indicadores (S3); sin ellos, el gerente comercial no puede decidir campañas y abastecimiento con un proceso repetible.
Fase objetivo al final del proyecto	Fase 4: Data warehouse. Es la meta del proyecto: se diseña en esta entrega y se implementa en las siguientes.
Brechas que cierra el proyecto	1. Fechas y códigos sin estandarizar (S1): Pentaho Data Integration con reglas de validación y limpieza (tabla 4.2, capa 2). 2. Ventas dispersas por tienda (S2): staging y almacén PostgreSQL con FactVentas (tabla 4.2, capas 2 y 3). 3. Indicadores sin definición común (S3): diccionario de datos y reglas de calidad (tabla 4.2, capa 5). 4. Informes armados a mano: reportes en Power BI Desktop para el gerente comercial (tabla 4.2, capa 4).

La fase objetivo es una meta de proyecto, no una afirmación de que la organización ya tenga un Data Warehouse en funcionamiento.

4. Arquitectura

Se propone una arquitectura de cinco capas. Pentaho Data Integration (PDI) extrae F1, F2 y F3 a un esquema staging en PostgreSQL, valida y normaliza fechas, códigos y nombres, y carga el esquema en estrella de FactVentas en el almacén PostgreSQL. F1 y F2 se cargan como tablas de contexto (serie mensual del sector comercio y localidades de Bogotá) para contrastar los resultados, no como ventas de RetailBI. Power BI Desktop consulta el almacén y presenta los indicadores al gerente comercial; Metabase queda como alternativa de uso libre. La capa de gobierno, metadatos, monitoreo y seguridad acompaña a las otras cuatro.

4.1 Diagrama de cinco capas del caso



Diseño propuesto para la Entrega 1 (datos de F3 sintéticos). Flechas continuas: flujo de datos; líneas discontinuas: capa transversal.

4.2 Componentes por capa

Capa	Componentes y herramientas	Función en el caso
1. Fuentes de datos	F1: anexos EMC del DANE (XLSX); F2: Dinámica empresarial de Bogotá (DBF/GPKG); F3: RetailBI_ventas_sinteticas_50000.csv (CSV sintético).	F3 aporta las 50.000 líneas de venta simuladas que alimentan FactVentas; F1 y F2 aportan contexto público del sector comercio y de las localidades de Bogotá.
2. Integración (ETL)	Pentaho Data Integration (transformaciones y job de carga por lotes); esquema staging en PostgreSQL; reglas de validación y limpieza.	Extraer F1, F2 y F3; normalizar fechas a AAAA-MM-DD, códigos y nombres; detectar duplicados de venta_id; verificar que total_venta_cop = cantidad × precio_unitario_cop − descuento_cop; cargar las dimensiones y FactVentas.
3. Almacén de datos	PostgreSQL (esquema dw): FactVentas, DimFecha, DimTienda, DimProducto y DimDescuento; tablas de contexto de F1 y F2.	Centralizar las ventas de las cinco tiendas con definiciones comunes y permitir consultas históricas por fecha, tienda, producto y descuento.
4. Usuario final	Power BI Desktop (alternativa: Metabase); gerente comercial y responsables de tienda.	Consultar ingresos netos, unidades y descuentos; filtrar por mes, tienda, producto y categoría; contrastar con la serie del DANE.
5. Gobierno, metadatos, monitoreo y seguridad	Diccionario de datos, bitácora de cargas de PDI (fecha, filas leídas, cargadas y rechazadas), reglas de calidad, roles de PostgreSQL y respaldos.	Documentar el linaje desde la fuente hasta el reporte, controlar accesos y detectar fallos de carga.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Indicadores comunes: ingresos brutos, descuentos, ingresos netos y unidades vendidas; análisis por mes, tienda, producto y categoría.	Responde a las preguntas P0–P3 y reduce discrepancias entre informes.
Arquitectura de datos	Modelo dimensional en estrella: tabla FactVentas y dimensiones DimFecha, DimTienda, DimProducto y DimDescuento.	Separa métricas de atributos descriptivos y facilita agregaciones.
Arquitectura técnica	Pentaho PDI para ETL, PostgreSQL como almacén y Power BI Desktop para visualización (Metabase como alternativa).	PDI y PostgreSQL son de uso libre y cubren la integración y el almacenamiento relacional; Power BI Desktop es gratuito para uso local, coherente con la decisión de despliegue de la tabla 4.4.
Arquitectura de producto	Conjunto de reportes comerciales con filtros por fecha, tienda, producto y categoría; actualización por lote documentada.	Entrega información reutilizable al gerente sin afirmar que el dashboard ya fue construido.

4.4 Decisión de despliegue

Criterio	On-premise	Opción cloud: PaaS administrado	Elección y razón
Costo	Requiere equipo local, instalación, mantenimiento y respaldos.	Pago recurrente; menor inversión inicial, costo según uso.	Para prototipo académico, local puede reducir costo; cloud se consideraría si se requiere acceso externo estable.
Seguridad y cumplimiento	Control directo de infraestructura, con responsabilidad local de protegerla.	Depende de configuración, proveedor, región y gestión de identidades.	Elegir local durante desarrollo con datos sintéticos; no se manejan datos personales reales.
Escalabilidad	Ampliación manual de recursos.	Puede escalar recursos con menor intervención.	Cloud es más flexible; no es indispensable para el prototipo.
Acceso móvil	Depende de red y configuración de acceso remoto.	Acceso desde internet con controles adecuados.	Para la entrega inicial se prioriza entorno local; cualquier publicación requiere revisión de seguridad.

Decisión propuesta: desarrollo local para la primera fase académica, utilizando datos sintéticos. Si en etapas posteriores se requiere acceso remoto multiusuario, evaluar un servicio cloud administrado comparando costos, región de almacenamiento, seguridad y disponibilidad.

5. Modelo dimensional

Se propone un esquema en estrella para analizar las ventas. Las dimensiones contienen atributos descriptivos y la tabla de hechos almacena métricas al nivel de detalle definido.

5.1 Proceso de negocio

El proceso modelado es la venta minorista en las cinco tiendas físicas de RetailBI: cada vez que se vende un producto se registra una línea con la tienda, la fecha, el producto, la cantidad, el precio unitario y el descuento aplicado. F3 no incluye número de factura o ticket, por lo que el modelo no agrupa líneas en transacciones ni calcula número de tickets o ticket promedio. Los precios, costos y descuentos de F3 son sintéticos: las métricas se definen en el diseño y los valores que se calculen con ellos solo demuestran el modelo; el costo y el margen simulados no representan rentabilidad real.

5.2 Granularidad

Una fila de la tabla de hechos representa una línea de venta: un producto vendido en una tienda en un día, con su cantidad, precio unitario y descuento, identificada por venta_id en F3. FactVentas tendrá una fila por cada línea de F3 (50.000 en el conjunto sintético) y conserva venta_id como dimensión degenerada para rastrear cada fila hasta su origen.

5.3 Métricas de la tabla de hechos

Métrica	Tipo de dato	Aditividad	Origen o fórmula
Cantidad vendida	Entero	Aditiva	Cantidad de unidades de la línea.
Precio unitario	Decimal / COP	No aditiva	precio_unitario_cop de F3; se promedia, no se suma.
Venta bruta	Decimal / COP	Aditiva	cantidad × precio_unitario_cop.
Descuento	Decimal / COP	Aditiva	descuento_cop de la línea.
Venta neta	Decimal / COP	Aditiva	venta_bruta − descuento; se valida contra total_venta_cop de F3.
Costo total simulado	Decimal / COP	Aditiva	cantidad × costo_unitario_cop; solo datos sintéticos.
Margen simulado	Decimal / COP	Aditiva	venta_neta − costo_total simulado; no representa rentabilidad real.

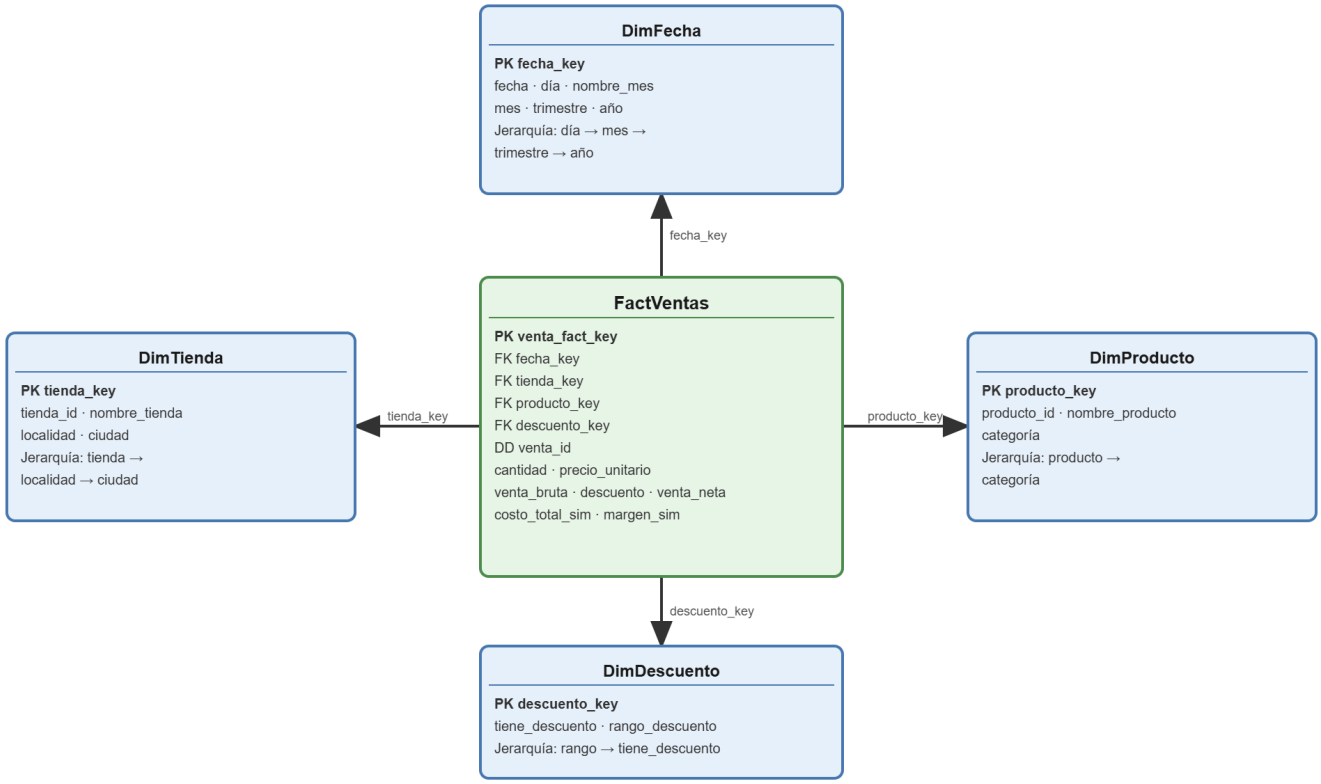
5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
DimFecha	fecha_key, fecha, día, mes, nombre_mes, trimestre, año	día → mes → trimestre → año	Generada en el ETL a partir de fecha_venta (F3).

DimTienda	tienda_key, tienda_id, nombre_tienda, localidad, ciudad	tienda → localidad → ciudad	tienda_id y tienda de F3; localidad y ciudad, de un catálogo de las cinco tiendas que documenta el equipo. F2 no identifica tiendas de RetailBI.
DimProducto	producto_key, producto_id, nombre_producto, categoría	producto → categoría	producto_id, producto y categoria de F3.
DimDescuento	descuento_key, tiene_descuento (sí/no), rango_descuento	rango_descuento → tiene_descuento	Derivada en el ETL a partir de descuento_cop y de la venta bruta (F3). Porcentaje de descuento = descuento_cop ÷ (cantidad × precio_unitario_cop). Rangos: Sin descuento (0 %), Bajo (más de 0 % hasta 5 %), Medio (más de 5 % hasta 10 %), Alto (más de 10 %).

Propósito y llave de cada dimensión: DimFecha (fecha_key, FK en FactVentas) permite comparar días, meses, trimestres y años; DimTienda (tienda_key) compara los cinco establecimientos; DimProducto (producto_key) analiza productos y categorías; DimDescuento (descuento_key) separa las líneas con y sin descuento, base de la definición común de venta neta (S3). DimFecha y DimProducto tienen jerarquías que salen directamente de F3. Se descartó una dimensión de canal porque F3 no tiene ese campo y el caso describe solo ventas en tiendas físicas.

5.5 Diagrama del esquema



Esquema en estrella (diseño lógico). PK: llave primaria; FK: llave foránea; DD: dimensión degenerada.

Llaves: DimFecha (fecha_key PK), DimTienda (tienda_key PK), DimProducto (producto_key PK), DimDescuento (descuento_key PK) y FactVentas (venta_fact_key PK; fecha_key, tienda_key, producto_key y descuento_key como FK; venta_id como dimensión degenerada).

Justificación del esquema en estrella: se elige porque simplifica las consultas analíticas y las agregaciones por fecha, tienda, producto y descuento. La categoría se mantiene como atributo de DimProducto y la localidad como atributo de DimTienda, en lugar de tablas aparte (copo de nieve), porque tienen pocos valores y desnormalizarlas evita uniones adicionales. Las dimensiones son descriptivas y la tabla de hechos conserva las métricas al nivel de detalle de una línea de venta. El esquema es un diseño lógico; no implica que las tablas ya estén creadas en una base de datos.

5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0	Venta neta, cantidad vendida	DimFecha (mes), DimTienda, DimProducto (categoría)
P1	Venta neta	DimProducto (producto, categoría),, DimFecha
P2	Cantidad vendida, venta neta	DimTienda, DimFecha
P3	Venta neta, cantidad vendida	DimFecha (mes, año)
P4	Venta neta y cantidad vendida agregadas por mes, insumo del modelo predictivo de una entrega posterior	DimFecha (mes), DimProducto, DimTienda

6. Referencias

- Departamento Administrativo Nacional de Estadística (DANE). (2026). *Encuesta Mensual de Comercio (EMC): Anexo comercio minorista – total nacional, agosto 2026* [Archivo de datos en Excel]. https://www.dane.gov.co/files/operaciones/EMC/anex-EMC-ComercioMinorista-ago2026.xlsx
- Departamento Administrativo Nacional de Estadística (DANE). (2026). *Encuesta Mensual de Comercio (EMC)*. https://www.dane.gov.co/index.php/estadisticas-por-tema/comercio-interno/encuesta-mensual-de-comercio-emc
- Secretaría Distrital de Desarrollo Económico. (2026). *Dinámica empresarial. Bogotá D.C. – Empresas 2026* [Conjunto de datos, CC BY-SA 4.0]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/dinamica-empresarial-bogota
- Equipo RetailBI. (2026). *RetailBI_ventas_sinteticas_50000.csv* [Conjunto de datos sintético creado para fines académicos].

Anexos

Anexo A. Diccionarios de datos-F1

Campo / variable	Descripción	Tipo de dato	Unidad / dominio	Uso en el proyecto
Año	Año de la observación. Solo aparece en la primera fila de cada año.	Entero	2019-2026	Dimensión temporal (contraste con DimFecha)
Mes	Mes de la observación. Llega como texto con espacios y puntos sobrantes (por ejemplo ' Enero. ').	Texto	Enero-Diciembre	Dimensión temporal (contraste con DimFecha)

Total comercio minorista sin vehículos automotores ni motocicletas[1]	Índice nominal de ventas del total del comercio minorista, sin las líneas de vehículos.	Decimal	Índice, base 2019 = 100	Referencia para contrastar la tendencia de venta neta de RetailBI
Total comercio minorista sin combustibles ni vehículos	Índice nominal de ventas excluyendo combustibles y vehículos.	Decimal	Índice, base 2019 = 100	Referencia más cercana al comercio de consumo cotidiano
Líneas de mercancía (1 a 17)	Una columna por línea (por ejemplo, alimentos, calzado y artículos de cuero).	Decimal	Índice, base 2019 = 100	Contraste por categoría de producto

Anexo B. Diccionarios de datos-F2

Campo (nombre exacto)	Descripción	Tipo de dato	Unidad / dominio	Uso en el proyecto
Periodo	Año de reporte.	Texto	2026	Dimensión temporal
Mes	Mes de corte del reporte.	Texto	Abril (corte del recurso)	Dimensión temporal
Localidad	Localidad de Bogotá donde se ubica la empresa. Incluye el valor Sin Localidad.	Texto	Localidades de Bogotá	Contexto territorial; contraste con DimTienda.localidad

Tamano empresarial	Clasificación de la empresa por tamaño.	Texto	Microempresa, Pequeña, Mediana, Grande	Segmentación
Rama de actividad economica	Rama de la actividad económica.	Texto	Ramas CIIU	Filtrar comercio
Codigo CIIU Rev. 4 A.C	Código de actividad económica (pierde el cero inicial; ej. 112 en lugar de 0112).	Texto	Códigos CIIU Rev. 4 A.C	Filtrar comercio al por menor (división 47)
Organizacion juridica	Tipo de organización jurídica de la empresa.	Texto	Persona natural, sociedades, etc.	Segmentación
Sexo del representante legal	Sexo del representante legal.	Texto	Categorías del recurso	No se usa en el modelo
Numero de empresas vigentes	Empresas con matrícula mercantil vigente.	Texto (convertir a entero)	Número de empresas	Contexto: tamaño del comercio por localidad
Numero de empresas creadas ano corrido	Empresas creadas en lo corrido del año.	Texto (convertir a entero)	Número de empresas	Contexto
Numero de empresas canceladas ano corrido	Empresas canceladas en lo corrido del año.	Texto (convertir a entero)	Número de empresas	Contexto

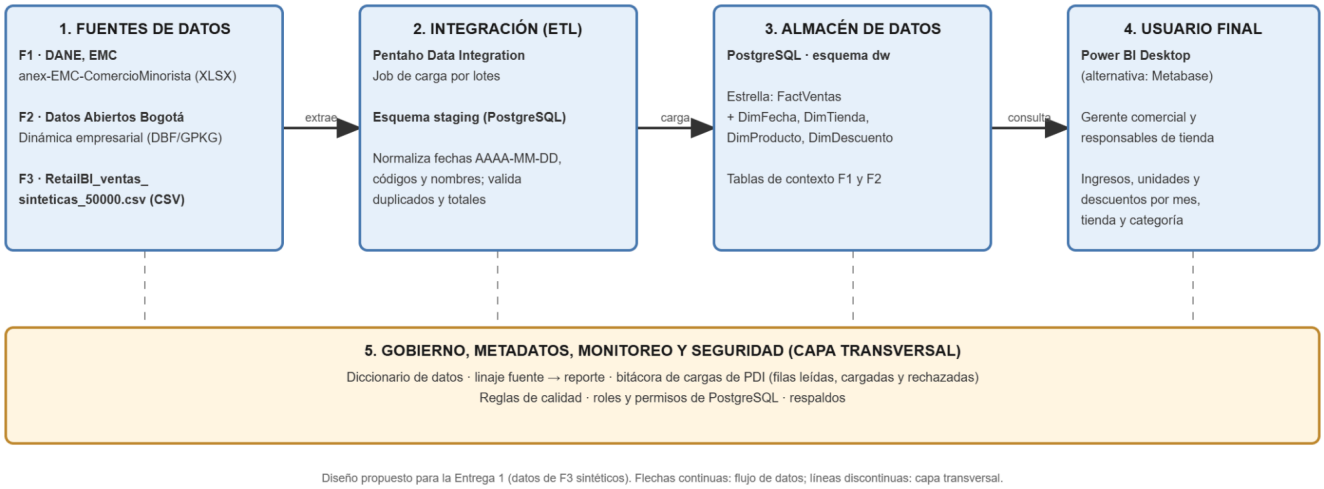
Anexo C. Diccionarios de datos-F3

Campo	Tipo	Descripción	Ejemplo	Regla de calidad que valida el ETL
venta_id	Texto	Identificador único de la línea simulada.	V000001	Sin duplicados
fecha_venta	Fecha (ISO)	Fecha de la línea de venta.	2024-04-23	Formato AAAA-MM-DD; en la copia de prueba se normalizan 23/04/2024 y 04-23-2024
tienda_id	Texto	Código de tienda.	T03	Debe existir en el catálogo de las cinco tiendas
tienda	Texto	Nombre de la tienda.	Kennedy	Sin espacios sobrantes ni variantes de escritura
producto_id	Texto	Código de producto.	P004	Debe existir en DimProducto
producto	Texto	Nombre del producto.	Yogur 1 L	Sin variantes de escritura
categoria	Texto	Categoría comercial.	Lacteos	Sin variaciones de tildes ni mayúsculas
cantidad	Entero	Unidades de la línea.	3	Mayor que 0, sin nulos
precio_unitario_cop	Entero (COP)	Precio unitario simulado.	7200	Mayor que 0 y dentro de rango
costo_unitario_cop	Entero (COP)	Costo unitario simulado (no es costo real).	5400	Mayor o igual a 0
descuento_cop	Entero (COP)	Descuento simulado de la línea.	500	Mayor o igual a 0 y menor o igual que cantidad × precio

total_venta_cop	Entero (COP)	Venta neta simulada.	21100	Debe ser igual a cantidad × precio – descuento (3 × 7200 – 500 = 21100)

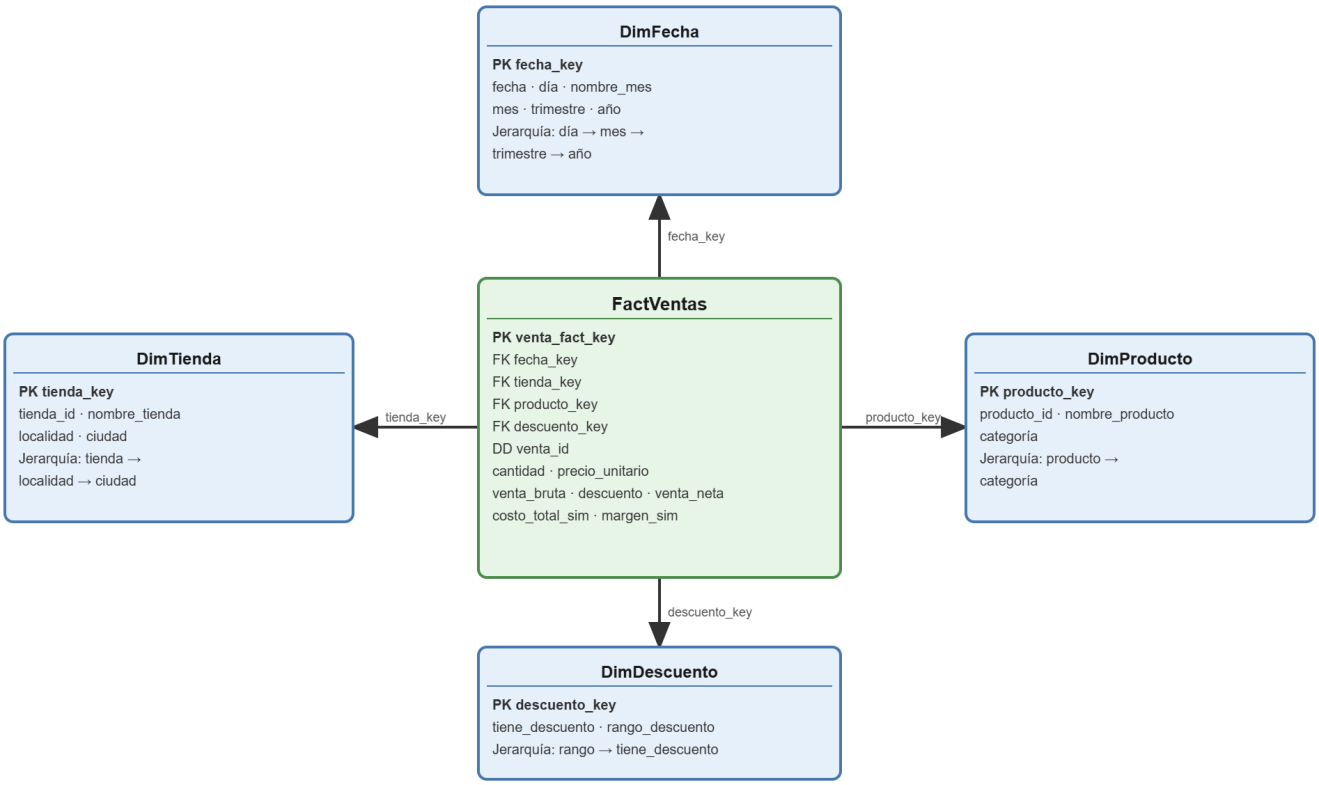
Anexo D. Diagramas a tamaño completo

Diagrama de arquitectura propuesto:



Diseño propuesto para la Entrega 1 (datos de F3 sintéticos). Flechas continuas: flujo de datos; líneas discontinuas: capa transversal.

Diagrama del modelo dimensional propuesto:



Esquema en estrella (diseño lógico). PK: llave primaria; FK: llave foránea; DD: dimensión degenerada.