**BUSINESS INTELLIGENCE**

PROYECTO FINAL · ENTREGA 1

# RETAILBI

*Diagnóstico, estrategia y diseño de una solución de BI*

| Integrante | Código |
|---|---|
| Juan David Pardo Gutierrez | 506241031 |
| Linda Valentina Quintero Quiroga | 506241056 |
| Daniel Felipe Rodríguez Angulo | 506241129 |

| Dato | Valor |
|---|---|
| Docente | Leandro Pájaro Fuentes |
| Fecha de entrega | 23/10/2026 |
| Repositorio GitHub | https://github.com/damoelrrr/RETAILBI-Business_Intelligence.git |

Los datos transaccionales que se adjuntan son sintéticos y se identifican expresamente como tales; las fuentes públicas externas se usan como contexto y contraste, no como ventas reales de RetailBI.

# Resumen de la entrega

RetailBI es una organización minorista ficticia con cinco establecimientos en Bogotá que presenta información comercial dispersa, formatos de fecha inconsistentes y definiciones no estandarizadas de indicadores. Se propone una solución de BI con integración ETL, almacenamiento centralizado en PostgreSQL, modelo dimensional en estrella y visualización para el gerente comercial. De acuerdo con el escenario planteado, la madurez actual corresponde a la fase 2 del BIMM de siete fases (Datos accesibles sin BI) y la fase objetivo es la fase 4 (Data warehouse). Una fila de la tabla de hechos FactVentas representa una línea de venta: un producto vendido en una tienda en un día, identificada por venta_id. El análisis cuantitativo de ventas se desarrollará con 50.000 registros sintéticos reproducibles; estos no representan ventas observadas de una empresa real.

# 1. Caso de negocio

El presente proyecto propone el diseño de una solución de Business Intelligence (BI) para una empresa minorista ficticia denominada RetailBI, dedicada a la comercialización de productos de consumo cotidiano a través de establecimientos físicos. La organización opera en un entorno comercial competitivo, en el que resulta fundamental conocer el comportamiento de las ventas, identificar las preferencias de los consumidores y disponer de información confiable para orientar las decisiones comerciales y operativas.

Para el desarrollo de este caso académico, se plantea que se cuente con cinco establecimientos ubicados en Bogotá D. C., Colombia, y una estructura administrativa central encargada de coordinar las actividades comerciales. La empresa comercializa diferentes categorías de productos y genera diariamente información relacionada con las transacciones, las cantidades vendidas, los precios y las fechas de compra. Estos datos representan un recurso importante para comprender el desempeño de la organización y detectar oportunidades de mejora en sus operaciones.

Sin embargo, se plantea que la información de la empresa se encuentra distribuida en diferentes herramientas de registro, sin una estructura centralizada que facilite su integración y análisis. Esta situación dificulta consolidar los resultados de los establecimientos, comparar periodos u obtener una visión global del comportamiento comercial. Además, la preparación de informes puede requerir tareas manuales que consumen tiempo y aumentan el riesgo de inconsistencias entre los resultados obtenidos por diferentes responsables.

La falta de integración de los datos limita la capacidad de la organización para responder oportunamente a preguntas relevantes para el negocio. Por ejemplo, resulta difícil identificar de manera consistente qué categorías presentan mayores ingresos, cómo varían las ventas entre distintos periodos o qué productos muestran cambios significativos en su demanda. Asimismo, la ausencia de indicadores estandarizados puede generar interpretaciones diferentes sobre el desempeño de las tiendas y dificultar la comparación de resultados.

Ante esta situación, se identifica la necesidad de diseñar una solución de Business Intelligence que permita transformar los datos disponibles en información organizada, accesible y útil para la toma de decisiones. La propuesta contempla una arquitectura que integre distintas fuentes de información mediante procesos de extracción, transformación y carga (ETL), con el propósito de organizar los datos en un almacén centralizado. Sobre esta estructura se plantea desarrollar un modelo dimensional que facilite el análisis de las ventas desde diferentes perspectivas, como el tiempo, los productos, las categorías y los establecimientos, siempre que las fuentes seleccionadas contengan los atributos necesarios.

La solución propuesta busca facilitar la elaboración de informes consistentes y la identificación de patrones comerciales mediante indicadores como los ingresos por ventas, las unidades comercializadas y la evolución temporal de la demanda. Estos análisis podrían contribuir a reconocer las categorías con mejor desempeño, detectar periodos de mayor actividad comercial y proporcionar información para planificar campañas promocionales y decisiones de abastecimiento. No obstante, la evaluación de la rentabilidad real o de los niveles efectivos de inventario requerirá disponer de datos adicionales sobre costos y existencias.

El principal usuario de la solución será el gerente comercial, quien necesita contar con información histórica comparable para evaluar los resultados y orientar las decisiones relacionadas con la oferta de productos y el desempeño de los

establecimientos. Otros usuarios potenciales serán los responsables de tienda y el personal administrativo, que podrán utilizar los informes para comprender las tendencias de ventas y apoyar la planificación de sus actividades.

En conclusión, el objetivo principal del proyecto es diseñar una solución de Business Intelligence que permita integrar y analizar la información comercial de RetailBI para mejorar la disponibilidad, la consistencia y la utilidad de los datos en la toma de decisiones**.** Para alcanzar este objetivo, la primera entrega se centrará en el diagnóstico de la situación empresarial, la identificación y evaluación de las fuentes de datos, el análisis de madurez de BI y el diseño de una arquitectura y un modelo dimensional adecuados para las necesidades identificadas.

De esta manera, RetailBI dispondrá de una propuesta estructurada para evolucionar desde una gestión de información fragmentada hacia un enfoque de análisis integrado y basado en datos. La solución constituirá una base para las siguientes fases del proyecto, en las que podrán implementarse los procesos de integración, el almacén de datos y las herramientas de visualización que permitan convertir el diseño en una solución analítica funcional.

**1.1 Organización y contexto**

RetailBI es una empresa minorista perteneciente al sector comercial, dedicada a vender al consumidor productos de consumo cotidiano. Por esta razón la organización cuenta con cinco establecimientos físicos ubicados en Bogotá, Colombia, y una estructura administrativa central encargada de coordinar las actividades comerciales y operativas.

La empresa dispone de responsables de ventas, encargados de tienda y personal administrativo que participa en el registro y seguimiento de las operaciones. Los establecimientos generan información sobre las transacciones, los productos vendidos, las cantidades y los precios. No obstante, los datos se gestionan mediante herramientas y archivos parcialmente independientes, sin una plataforma centralizada que permita consolidar la información de todas las tiendas.

El máximo responsable del proyecto es el gerente comercial, quien debe evaluar el desempeño de las ventas y orientar las decisiones relacionadas con las categorías de productos, las campañas comerciales y las necesidades de abastecimiento. Para ello, necesita disponer de información histórica comparable y de indicadores confiables que permitan identificar patrones y diferencias entre periodos y establecimientos.

En la situación actual descrita, el gerente comercial no puede determinar de forma rápida y consistente qué categorías y productos presentan un mejor desempeño a lo largo del tiempo, cómo varían las ventas entre establecimientos ni qué tendencias históricas deberían tenerse en cuenta para planificar las compras. Estas limitaciones se deben, en el escenario planteado, a la dispersión de los datos, a la ausencia de definiciones comunes para los indicadores y a la falta de una estructura integrada para el análisis.

Por esta razón, se propone diseñar una solución de Business Intelligence basada en un almacén de datos y un modelo dimensional que consoliden la información disponible y permitan analizar las ventas desde distintas perspectivas. La viabilidad de estos análisis dependerá de la disponibilidad, calidad y compatibilidad de las fuentes que se seleccionen y validen durante el desarrollo del proyecto.

# 1.2 Síntomas de arquitectura accidental

| # | Síntoma | Evidencia en el caso | Capa afectada |
|---|---|---|---|
| S1 | Fechas con formatos diferentes | Una tienda registra la fecha como 23/04/2024 y otra como 04-23-2024; al consolidar, una misma venta puede quedar en el mes equivocado. | Fuentes / Integración |
| S2 | Datos de ventas dispersos | Cada tienda conserva archivos separados y el gerente debe reunirlos manualmente para obtener un consolidado. | Fuentes / Integración / Almacén |

| | | | |
|---|---|---|---|
| S3 | Indicadores sin definición común | Un informe calcula la venta descontando los descuentos y otro no, así que el total de un mismo mes no coincide entre informes. | Almacén / Gobierno de datos |

## 1.3 Preguntas de negocio

| # | Pregunta | Tipo | Justificación |
|---|---|---|---|
| P0 | ¿Cómo evolucionan los ingresos y las unidades vendidas por tienda, categoría y mes? | BI | Es BI porque describe, con datos históricos estructurados, cómo evolucionaron ingresos y unidades; no predice ni recomienda. |
| P1 | ¿Qué productos y categorías generan mayores ingresos netos? | BI | Es BI porque ordena productos y categorías según los ingresos netos ya registrados: es un análisis descriptivo del pasado. |
| P2 | ¿Qué tiendas presentan mayor volumen de unidades vendidas? | BI | Es BI porque compara las unidades ya vendidas por tienda a partir de datos estructurados del almacén. |
| P3 | ¿Qué meses muestran aumentos o disminuciones en las ventas? | BI | Es BI porque identifica, sobre la serie mensual histórica, las alzas y caídas que ya ocurrieron. |
| P4 | ¿Qué nivel de ventas podría esperarse para los próximos meses a partir del historial? | BA | Es BA porque estima ventas futuras con un modelo predictivo entrenado con la historia mensual de 2023 a 2025. |

# 2. Inventario de fuentes

## 2.1 Fuentes

| Fuente | Procedencia | Formato | Registros / periodo | Descarga | Licencia / uso |
|---|---|---|---|---|---|
| F1- DANE, Encuesta Mensual de Comercio (EMC): https://www.dane.gov.co/index.php/estadisticas-por-tema/comercio-interno/encuesta-mensual-de-comercio-emc | DANE | XLSX (anex-EMC-ComercioMinorista-ago2026.xlsx) | Hoja 2.1 del anexo de comercio minorista (índices de ventas nominales por grupo de mercancía, base 2019 = 100): 92 registros mensuales, de enero de 2019 a agosto de 2026. | 23/10/2026 | Uso, aprovechamiento, transformación y análisis autorizados con atribución al DANE; sujeto a los términos y condiciones del portal. |
| F2-Datos Abiertos Bogotá, Dinámica | Secretaría Distrital de Desarrollo | DBF/GPKG | Recurso Empresas 2026 (DBF): 39.941 | 23/10/2026 | Creative Commons Attribution-Share |

| | | | | | |
|---|---|---|---|---|---|
| empresarial: https://datosabiertos.bogota.gov.co/dataset/dinamica-empresarial-bogota | Económico / Datos Abiertos Bogotá | | registros con corte a abril de 2026; capas anuales en GPKG para 2023, 2024 y 2025. | | Alike 4.0 (CC BY-SA 4.0), según ficha del portal. |
| F3-RetailBI_ventas_sinteticas_50000.csv, generado para este proyecto | Elaboración propia | CSV | 50.000 filas de ventas; periodo 2023 a 2025 (tres años). | 23/10/2026 | Datos sintéticos creados para fines académicos; no corresponden a ventas reales. |

## 2.2 Problemas de calidad detectados

| Fuente | Campo | Problema | Ejemplo / forma de documentarlo |
|---|---|---|---|
| F1 | Mes y Año (hoja 2.1) | El mes es texto con espacios iniciales y, en un caso, un punto sobrante; el año solo aparece en la primera fila de cada año y debajo de los datos hay filas de notas. | Enero de 2019 aparece como '  Enero.' y febrero de 2019 tiene el año vacío; tras agosto de 2026 sigue la fila 'Fuente: DANE - EMC'. |
| F2 | Codigo CIIU Rev. 4 A.C y Localidad | Los códigos CIIU pierden el cero inicial (2.147 filas con menos de cuatro dígitos), 2.383 filas tienen 'Sin Localidad' y los nombres de localidad van sin tildes. | _id 130179: CIIU '112' en lugar de '0112'; _id 157221: Localidad 'Sin Localidad'; 'Engativa' en lugar de 'Engativá'. |
| F3 | fecha_venta, tienda, producto | Los datos sintéticos llegan limpios; como permite el enunciado, en una copia de prueba se introducen formatos de fecha mezclados, espacios en nombres y nulos controlados. | Ejemplo simulado: '23/04/2024' y '04-23-2024'; la inconsistencia es deliberada y queda documentada. |

Los ejemplos de F1 y F2 se tomaron de los archivos publicados por el DANE y por Datos Abiertos Bogotá, consultados el 23/10/2026; los de F3 son inconsistencias introducidas a propósito en una copia de prueba.

# 3. Diagnóstico de madurez

| Elemento | Respuesta |
|---|---|
| Fase actual | Fase 2: Datos accesibles sin BI. |
| Evidencia | S2: las ventas de las cinco tiendas existen en archivos separados, es decir, los datos son accesibles, pero el consolidado se arma a mano.<br>S1: cada fuente registra la fecha en un formato distinto y ningún proceso la normaliza.<br>S3: no hay definiciones comunes de venta neta ni de descuento, así que los totales de distintos informes no son comparables.<br>Los tres síntomas son parte del escenario planteado; en F3 las fechas vienen en formato ISO y S1 se simula en una copia de prueba (tabla 2.2). |
| Por qué no es la fase siguiente | La fase 3 (Procesos formales de decisión basados en datos) exige que las decisiones sigan un proceso establecido con datos consolidados e indicadores definidos. A RetailBI le falta un consolidado único de las cinco tiendas (S2), fechas homogéneas para comparar periodos (S1) y definiciones comunes de los |

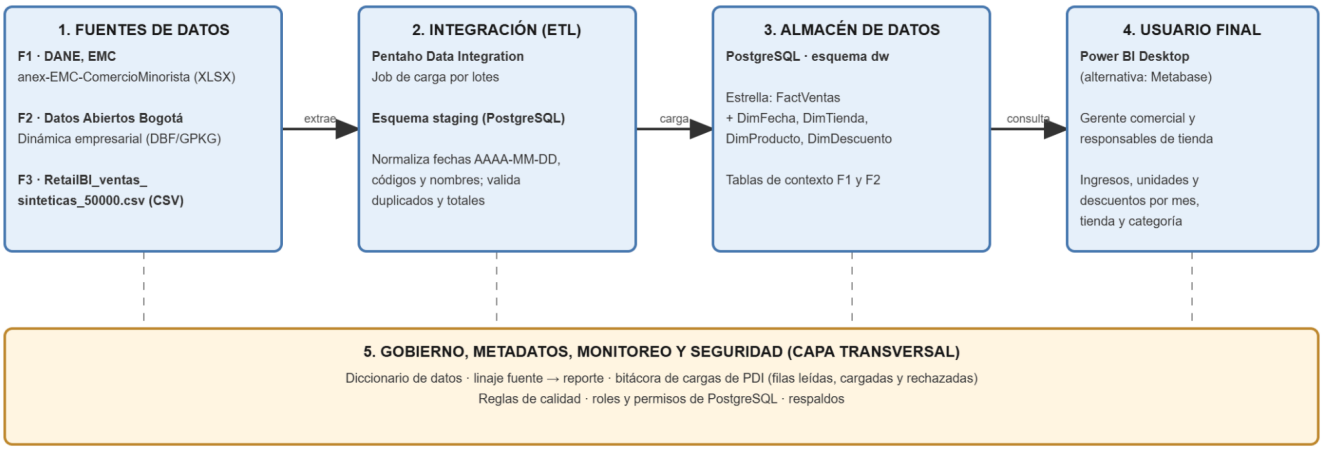
| | |
|---|---|
| | indicadores (S3); sin ellos, el gerente comercial no puede decidir campañas y abastecimiento con un proceso repetible. |
| Fase objetivo al final del proyecto | Fase 4: Data warehouse. Es la meta del proyecto: se diseña en esta entrega y se implementa en las siguientes. |
| Brechas que cierra el proyecto | 1. Fechas y códigos sin estandarizar (S1): Pentaho Data Integration con reglas de validación y limpieza (tabla 4.2, capa 2).<br>2. Ventas dispersas por tienda (S2): staging y almacén PostgreSQL con FactVentas (tabla 4.2, capas 2 y 3).<br>3. Indicadores sin definición común (S3): diccionario de datos y reglas de calidad (tabla 4.2, capa 5).<br>4. Informes armados a mano: reportes en Power BI Desktop para el gerente comercial (tabla 4.2, capa 4). |

La fase objetivo es una meta de proyecto, no una afirmación de que la organización ya tenga un Data Warehouse en funcionamiento.

# 4. Arquitectura

Se propone una arquitectura de cinco capas. Pentaho Data Integration (PDI) extrae F1, F2 y F3 a un esquema staging en PostgreSQL, valida y normaliza fechas, códigos y nombres, y carga el esquema en estrella de FactVentas en el almacén PostgreSQL. F1 y F2 se cargan como tablas de contexto (serie mensual del sector comercio y localidades de Bogotá) para contrastar los resultados, no como ventas de RetailBI. Power BI Desktop consulta el almacén y presenta los indicadores al gerente comercial; Metabase queda como alternativa de uso libre. La capa de gobierno, metadatos, monitoreo y seguridad acompaña a las otras cuatro.

## 4.1 Diagrama de cinco capas del caso




Diseño propuesto para la Entrega 1 (datos de F3 sintéticos). Flechas continuas: flujo de datos; líneas discontinuas: capa transversal.

## 4.2 Componentes por capa

| Capa | Componentes y herramientas | Función en el caso |
|---|---|---|
| 1. Fuentes de datos | F1: anexos EMC del DANE (XLSX); F2: Dinámica empresarial de Bogotá (DBF/GPKG); F3: RetailBI_ventas_sinteticas_50000.csv (CSV sintético). | F3 aporta las 50.000 líneas de venta simuladas que alimentan FactVentas; F1 y F2 aportan contexto público del sector comercio y de las localidades de Bogotá. |
| 2. Integración (ETL) | Pentaho Data Integration (transformaciones y job de carga por lotes); esquema staging en PostgreSQL; reglas de validación y limpieza. | Extraer F1, F2 y F3; normalizar fechas a AAAA-MM-DD, códigos y nombres; detectar duplicados de venta_id; verificar que total_venta_cop = cantidad × precio_unitario_cop − descuento_cop; cargar las dimensiones y FactVentas. |
| 3. Almacén de datos | PostgreSQL (esquema dw): FactVentas, DimFecha, DimTienda, DimProducto y DimDescuento; tablas de contexto de F1 y F2. | Centralizar las ventas de las cinco tiendas con definiciones comunes y permitir consultas históricas por fecha, tienda, producto y descuento. |
| 4. Usuario final | Power BI Desktop (alternativa: Metabase); gerente comercial y responsables de tienda. | Consultar ingresos netos, unidades y descuentos; filtrar por mes, tienda, producto |

| | | |
|---|---|---|
| | | y categoría; contrastar con la serie del DANE. |
| 5. Gobierno, metadatos, monitoreo y seguridad | Diccionario de datos, bitácora de cargas de PDI (fecha, filas leídas, cargadas y rechazadas), reglas de calidad, roles de PostgreSQL y respaldos. | Documentar el linaje desde la fuente hasta el reporte, controlar accesos y detectar fallos de carga. |

### 4.3 Marco de Referencia de cuatro categorías

| Categoría | Decisión tomada | Justificación |
|---|---|---|
| Arquitectura de información | Indicadores comunes: ingresos brutos, descuentos, ingresos netos y unidades vendidas; análisis por mes, tienda, producto y categoría. | Responde a las preguntas P0–P3 y reduce discrepancias entre informes. |
| Arquitectura de datos | Modelo dimensional en estrella: tabla FactVentas y dimensiones DimFecha, DimTienda, DimProducto y DimDescuento. | Separa métricas de atributos descriptivos y facilita agregaciones. |
| Arquitectura técnica | Pentaho PDI para ETL, PostgreSQL como almacén y Power BI Desktop para visualización (Metabase como alternativa). | PDI y PostgreSQL son de uso libre y cubren la integración y el almacenamiento relacional; Power BI Desktop es gratuito para uso local, coherente con la decisión de despliegue de la tabla 4.4. |
| Arquitectura de producto | Conjunto de reportes comerciales con filtros por fecha, tienda, producto y categoría; actualización por lote documentada. | Entrega información reutilizable al gerente sin afirmar que el dashboard ya fue construido. |

### 4.4 Decisión de despliegue

| Criterio | On-premise | Opción cloud: PaaS administrado | Elección y razón |
|---|---|---|---|
| Costo | Requiere equipo local, instalación, mantenimiento y respaldos. | Pago recurrente; menor inversión inicial, costo según uso. | Para prototipo académico, local puede reducir costo; cloud se consideraría si se requiere acceso externo estable. |
| Seguridad y cumplimiento | Control directo de infraestructura, con responsabilidad local de protegerla. | Depende de configuración, proveedor, región y gestión de identidades. | Elegir local durante desarrollo con datos sintéticos; no se manejan datos personales reales. |
| Escalabilidad | Ampliación manual de recursos. | Puede escalar recursos con menor intervención. | Cloud es más flexible; no es indispensable para el prototipo. |
| Acceso móvil | Depende de red y configuración de acceso remoto. | Acceso desde internet con controles adecuados. | Para la entrega inicial se prioriza entorno local; cualquier publicación requiere revisión de seguridad. |

Decisión propuesta: desarrollo local para la primera fase académica, utilizando datos sintéticos. Si en etapas posteriores se requiere acceso remoto multiusuario, evaluar un servicio cloud administrado comparando costos, región de almacenamiento, seguridad y disponibilidad.

# 5. Modelo dimensional

Se propone un esquema en estrella para analizar las ventas. Las dimensiones contienen atributos descriptivos y la tabla de hechos almacena métricas al nivel de detalle definido.

### 5.1 Proceso de negocio

El proceso modelado es la venta minorista en las cinco tiendas físicas de RetailBI: cada vez que se vende un producto se registra una línea con la tienda, la fecha, el producto, la cantidad, el precio unitario y el descuento aplicado. F3 no incluye número de factura o ticket, por lo que el modelo no agrupa líneas en transacciones ni calcula número de tickets o ticket promedio. Los precios, costos y descuentos de F3 son sintéticos: las métricas se definen en el diseño y los valores que se calculen con ellos solo demuestran el modelo; el costo y el margen simulados no representan rentabilidad real.

## 5.2 Granularidad

Una fila de la tabla de hechos representa una línea de venta: un producto vendido en una tienda en un día, con su cantidad, precio unitario y descuento, identificada por venta_id en F3. FactVentas tendrá una fila por cada línea de F3 (50.000 en el conjunto sintético) y conserva venta_id como dimensión degenerada para rastrear cada fila hasta su origen.

## 5.3 Métricas de la tabla de hechos

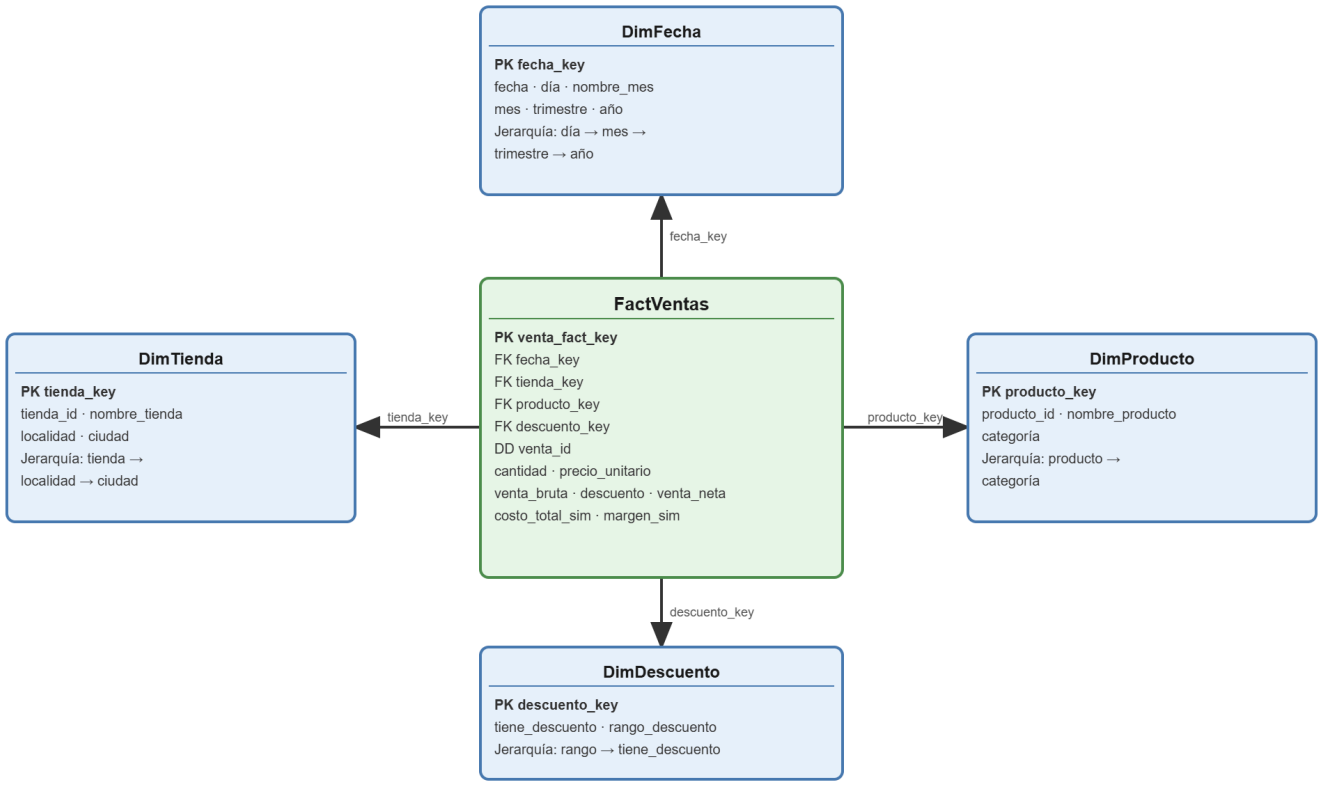
| Métrica | Tipo de dato | Aditividad | Origen o fórmula |
|---|---|---|---|
| Cantidad vendida | Entero | Aditiva | Cantidad de unidades de la línea. |
| Precio unitario | Decimal / COP | No aditiva | precio_unitario_cop de F3; se promedia, no se suma. |
| Venta bruta | Decimal / COP | Aditiva | cantidad × precio_unitario_cop. |
| Descuento | Decimal / COP | Aditiva | descuento_cop de la línea. |
| Venta neta | Decimal / COP | Aditiva | venta_bruta − descuento; se valida contra total_venta_cop de F3. |
| Costo total simulado | Decimal / COP | Aditiva | cantidad × costo_unitario_cop; solo datos sintéticos. |
| Margen simulado | Decimal / COP | Aditiva | venta_neta − costo_total simulado; no representa rentabilidad real. |

## 5.4 Dimensiones

| Dimensión | Atributos principales | Jerarquía | Fuente |
|---|---|---|---|
| DimFecha | fecha_key, fecha, día, mes, nombre_mes, trimestre, año | día → mes → trimestre → año | Generada en el ETL a partir de fecha_venta (F3). |
| DimTienda | tienda_key, tienda_id, nombre_tienda, localidad, ciudad | tienda → localidad → ciudad | tienda_id y tienda de F3; localidad y ciudad, de un catálogo de las cinco tiendas que documenta el equipo. F2 no identifica tiendas de RetailBI. |
| DimProducto | producto_key, producto_id, nombre_producto, categoría | producto → categoría | producto_id, producto y categoria de F3. |
| DimDescuento | descuento_key, tiene_descuento (sí/no), rango_descuento | rango_descuento → tiene_descuento | Derivada en el ETL a partir de descuento_cop y de la venta bruta (F3). Porcentaje de descuento = descuento_cop ÷ (cantidad × precio_unitario_cop). Rangos: Sin descuento (0 %), Bajo (más de 0 % hasta 5 %), Medio (más de 5 % hasta 10 %), Alto (más de 10 %). |

Propósito y llave de cada dimensión: DimFecha (fecha_key, FK en FactVentas) permite comparar días, meses, trimestres y años; DimTienda (tienda_key) compara los cinco establecimientos; DimProducto (producto_key) analiza productos y categorías; DimDescuento (descuento_key) separa las líneas con y sin descuento, base de la definición común de venta neta (S3). DimFecha y DimProducto tienen jerarquías que salen directamente de F3. Se descartó una dimensión de canal porque F3 no tiene ese campo y el caso describe solo ventas en tiendas físicas.

## 5.5 Diagrama del esquema




Esquema en estrella (diseño lógico). PK: llave primaria; FK: llave foránea; DD: dimensión degenerada.

Llaves: DimFecha (fecha_key PK), DimTienda (tienda_key PK), DimProducto (producto_key PK), DimDescuento (descuento_key PK) y FactVentas (venta_fact_key PK; fecha_key, tienda_key, producto_key y descuento_key como FK; venta_id como dimensión degenerada).

Justificación del esquema en estrella: se elige porque simplifica las consultas analíticas y las agregaciones por fecha, tienda, producto y descuento. La categoría se mantiene como atributo de DimProducto y la localidad como atributo de DimTienda, en lugar de tablas aparte (copo de nieve), porque tienen pocos valores y desnormalizarlas evita uniones adicionales. Las dimensiones son descriptivas y la tabla de hechos conserva las métricas al nivel de detalle de una línea de venta. El esquema es un diseño lógico; no implica que las tablas ya estén creadas en una base de datos.

## 5.6 Trazabilidad con las preguntas

| Pregunta | Métricas que usa | Dimensiones que usa |
|---|---|---|
| P0 | Venta neta, cantidad vendida | DimFecha (mes), DimTienda, DimProducto (categoría) |
| P1 | Venta neta | DimProducto (producto, categoría),, DimFecha |
| P2 | Cantidad vendida, venta neta | DimTienda, DimFecha |
| P3 | Venta neta, cantidad vendida | DimFecha (mes, año) |
| P4 | Venta neta y cantidad vendida agregadas por mes, insumo del modelo predictivo de una entrega posterior | DimFecha (mes), DimProducto, DimTienda |

# 6. Referencias


- Departamento Administrativo Nacional de Estadística (DANE). (2026). *Encuesta Mensual de Comercio (EMC): Anexo comercio minorista – total nacional, agosto 2026* [Archivo de datos en Excel]. https://www.dane.gov.co/files/operaciones/EMC/anex-EMC-ComercioMinorista-ago2026.xlsx

- Departamento Administrativo Nacional de Estadística (DANE). (2026). *Encuesta Mensual de Comercio (EMC)*. https://www.dane.gov.co/index.php/estadisticas-por-tema/comercio-interno/encuesta-mensual-de-comercio-emc
- Secretaría Distrital de Desarrollo Económico. (2026). *Dinámica empresarial. Bogotá D.C. – Empresas 2026* [Conjunto de datos, CC BY-SA 4.0]. Datos Abiertos Bogotá. https://datosabiertos.bogota.gov.co/dataset/dinamica-empresarial-bogota
- Equipo RetailBI. (2026). *RetailBI_ventas_sinteticas_50000.csv* [Conjunto de datos sintético creado para fines académicos].


# Anexos

## Anexo A. Diccionarios de datos-F1

| Campo / variable | Descripción | Tipo de dato | Unidad / dominio | Uso en el proyecto |
|---|---|---|---|---|
| Año | Año de la observación. Solo aparece en la primera fila de cada año. | Entero | 2019-2026 | Dimensión temporal (contraste con DimFecha) |
| Mes | Mes de la observación. Llega como texto con espacios y puntos sobrantes (por ejemplo ' Enero. '). | Texto | Enero-Diciembre | Dimensión temporal (contraste con DimFecha) |
| Total comercio minorista sin vehículos automotores ni motocicletas[1] | Índice nominal de ventas del total del comercio minorista, sin las líneas de vehículos. | Decimal | Índice, base 2019 = 100 | Referencia para contrastar la tendencia de venta neta de RetailBI |
| Total comercio minorista sin combustibles ni vehículos | Índice nominal de ventas excluyendo combustibles y vehículos. | Decimal | Índice, base 2019 = 100 | Referencia más cercana al comercio de consumo cotidiano |
| Líneas de mercancía (1 a 17) | Una columna por línea (por ejemplo, alimentos, calzado y artículos de cuero). | Decimal | Índice, base 2019 = 100 | Contraste por categoría de producto |

## Anexo B. Diccionarios de datos-F2

| Campo (nombre exacto) | Descripción | Tipo de dato | Unidad / dominio | Uso en el proyecto |
|---|---|---|---|---|
| **Periodo** | Año de reporte. | Texto | 2026 | Dimensión temporal |
| **Mes** | Mes de corte del reporte. | Texto | Abril (corte del recurso) | Dimensión temporal |
| **Localidad** | Localidad de Bogotá donde se ubica la empresa. Incluye el valor Sin Localidad. | Texto | Localidades de Bogotá | Contexto territorial; contraste con DimTienda.localidad |
| **Tamano empresarial** | Clasificación de la empresa por tamaño. | Texto | Microempresa, Pequeña, Mediana, Grande | Segmentación |
| **Rama de actividad economica** | Rama de la actividad económica. | Texto | Ramas CIIU | Filtrar comercio |
| **Codigo CIIU Rev. 4 A.C** | Código de actividad económica (pierde el cero inicial; ej. 112 en lugar de 0112). | Texto | Códigos CIIU Rev. 4 A.C | Filtrar comercio al por menor (división 47) |
| **Organizacion juridica** | Tipo de organización jurídica de la empresa. | Texto | Persona natural, sociedades, etc. | Segmentación |

| | | | | |
|---|---|---|---|---|
| **Sexo del representante legal** | Sexo del representante legal. | Texto | Categorías del recurso | No se usa en el modelo |
| **Numero de empresas vigentes** | Empresas con matrícula mercantil vigente. | Texto (convertir a entero) | Número de empresas | Contexto: tamaño del comercio por localidad |
| **Numero de empresas creadas ano corrido** | Empresas creadas en lo corrido del año. | Texto (convertir a entero) | Número de empresas | Contexto |
| **Numero de empresas canceladas ano corrido** | Empresas canceladas en lo corrido del año. | Texto (convertir a entero) | Número de empresas | Contexto |

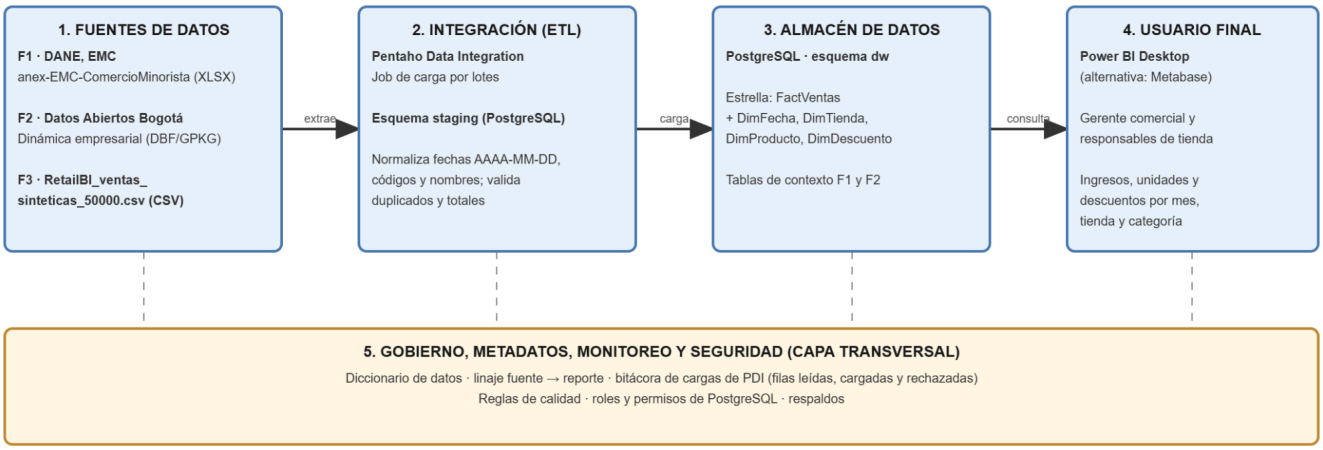
## Anexo C. Diccionarios de datos-F3

| Campo | Tipo | Descripción | Ejemplo | Regla de calidad que valida el ETL |
|---|---|---|---|---|
| **venta_id** | Texto | Identificador único de la línea simulada. | V000001 | Sin duplicados |
| **fecha_venta** | Fecha (ISO) | Fecha de la línea de venta. | 2024-04-23 | Formato AAAA-MM-DD; en la copia de prueba se normalizan 23/04/2024 y 04-23-2024 |
| **tienda_id** | Texto | Código de tienda. | T03 | Debe existir en el catálogo de las cinco tiendas |
| **tienda** | Texto | Nombre de la tienda. | Kennedy | Sin espacios sobrantes ni |

| | | | | |
|---|---|---|---|---|
| | | | | variantes de escritura |
| **producto_id** | Texto | Código de producto. | P004 | Debe existir en DimProducto |
| **producto** | Texto | Nombre del producto. | Yogur 1 L | Sin variantes de escritura |
| **categoria** | Texto | Categoría comercial. | Lacteos | Sin variaciones de tildes ni mayúsculas |
| **cantidad** | Entero | Unidades de la línea. | 3 | Mayor que 0, sin nulos |
| **precio_unitario_cop** | Entero (COP) | Precio unitario simulado. | 7200 | Mayor que 0 y dentro de rango |
| **costo_unitario_cop** | Entero (COP) | Costo unitario simulado (no es costo real). | 5400 | Mayor o igual a 0 |
| **descuento_cop** | Entero (COP) | Descuento simulado de la línea. | 500 | Mayor o igual a 0 y menor o igual que cantidad × precio |
| **total_venta_cop** | Entero (COP) | Venta neta simulada. | 21100 | Debe ser igual a cantidad × precio – descuento (3 × 7200 – 500 = 21100) |

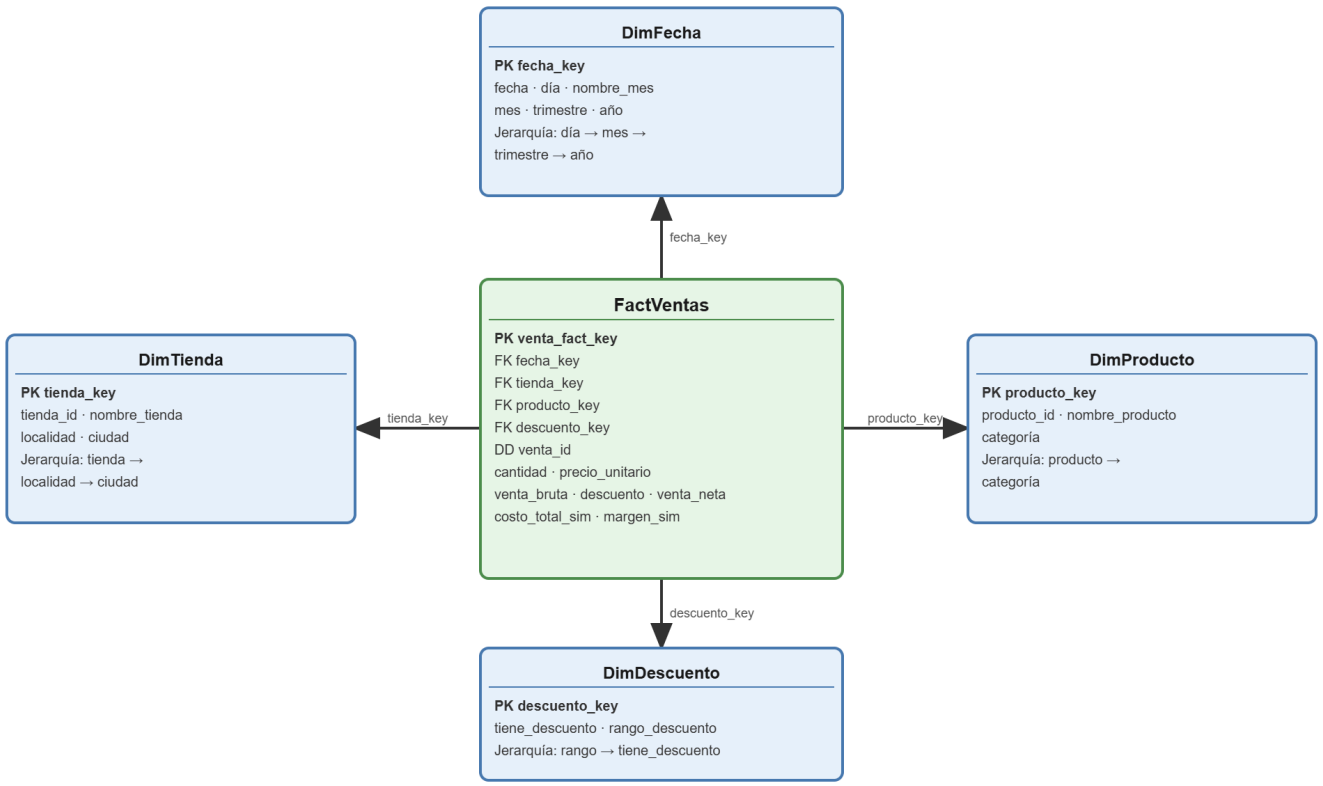
## Anexo D. Diagramas a tamaño completo

Diagrama de arquitectura propuesto:




Diseño propuesto para la Entrega 1 (datos de F3 sintéticos). Flechas continuas: flujo de datos; líneas discontinuas: capa transversal.

Diagrama del modelo dimensional propuesto:




Esquema en estrella (diseño lógico). PK: llave primaria; FK: llave foránea; DD: dimensión degenerada.